

Weekend Agent 设计文档

Weekend Agent 面向“周末临时出门”的本地生活规划场景：用户只输入一句自然语言，系统输出一套包含活动、餐厅、路线、预算和预约动作的可执行方案，并支持对整套方案或单个节点持续微调。

本方案的核心不是把本地生活服务做成一个“搜索结果列表”，而是把模糊的周末目标拆解为可执行的时间线。Agent 需要同时处理自然语言理解、候选召回、预算约束、路线时间、亲子适配、用户反馈和预约动作，因此我们将系统设计为“Planning Core + Tool Adapter + Preference Memory”的可替换架构。

1. Planning 策略

系统采用“关键词优先、数据库召回、必要时 LLM 推理”的混合 Planning 策略。用户输入后，Parser 先抽取人数、孩子年龄、预算、时间、距离、天气、餐饮和活动偏好，并计算关键词命中率；命中率高时直接走数据库召回，表达开放、连续否定或带有明确调整方向时再切换到 LLM Adapter。

在首轮规划中，Agent 先把用户目标转为结构化约束，再从活动、餐厅、展览和路线工具中召回候选。候选不会直接展示给用户，而是先经过规则评分：预算越接近但不超支得分越高，通勤越短得分越高，亲子友好、可预约、室内避雨、少排队等标签会提高优先级。这样可以保证 Demo 阶段即使没有真实大模型，也能解释为什么推荐这套方案。

用户场景	路由策略	规划动作
关键词命中率 ≥ 0.55	database	从本地 POI/活动/餐厅库召回，按预算、距离、亲子、排队、余位打分
关键词命中率 < 0.55	llm_reasoning	将开放自然语言转成结构化约束，再参与候选重排
整套方案连续拒绝 ≥ 2 次	llm_reasoning	跳出固定组合，生成新的活动-餐厅-路线结构
输入整体调整方向	llm_reasoning	例如“更便宜”“减少打车”“更适合孩子”，重算总价、时长和路线
输入单节点调整方向	llm_node_adjustment_adapter	只替换目标节点，已赞同节点必须保留，并重新计算全局指标

最终方案由“活动/展览 + 休息 + 餐厅 + 往返路线”组成，系统一次只返回 1 套推荐方案。用户对节点或整套方案的赞同/拒绝会进入反馈状态：赞同节点在后续重规划中锁定保留；拒绝节点进入排除集；如果用户误点，赞同和拒绝可互相覆盖，避免状态不可逆。

重规划分为三层：第一层在当前数据库候选内替换，适合“换个餐厅”“更近一点”等低风险修改；第二层调用 LLM Adapter 将“更便宜”“更适合孩子”等方向转成约束，再重排候选；第三层在连续拒绝整套方案时跳出原始组合，重新生成活动-餐厅-路线结构。每一次替换节点后都会重新计算总价、总时长、最长通勤和预约状态，避免局部修改破坏整体方案。

2. 工具调用链路

2.1 技术链路




图 1. 技术链路采用 Client-Agent-Reasoning-Tools 四层结构：高命中走数据库，低命中或强反馈走 LLM Adapter，最终统一进入校验器。

首次规划链路为: `POST /api/plan -> parse_user_intent -> keyword_match -> retrieval_mode -> search_activities/search_live_events/search_restaurants -> get_weather/get_route_time -> validate_plan -> rank -> recommended_plan`。

节点修改链路为: `POST /api/action reject_item -> 更新 approved/rejected 状态 -> build_item_adjustment_directive -> llm_node_adjustment_adapter -> 替换目标节点 -> 重算价格/时间/路线`。整套方案拒绝链路为: `reject plan -> rejected plan keys -> 数据库内换下一套 -> 连续拒绝或带方向时切换 LLM 推理重排`。

工具调用采用统一的 Tool Adapter 约定：每个候选都返回 `id/name/type/location/duration/cost/tags/reservation/mock_url` 等字段，Planning Core 只依赖统一字段而不依赖具体平台。这样餐厅可以从 Mock 数据替换到美团 POI，打车可以从 Mock 价格替换到滴滴车型报价，展览活动可以从静态 JSON 替换到实时搜索 API，而上层计划生成逻辑保持稳定。

2.2 数据链路和预留接口




图 2. 数据链路将用户意图、候选召回、上下文工具、偏好记忆和执行接口串联；当前为 Mock，可按模块替换真实接口。

当前工具均为 Mock 实现，但接口边界已预留：`/api/search/events` 可接展览/博览会实时检索，`mock_meituan_url` 后续替换为 `meituan_deeplink`，`/api/ride/options` 可接滴滴车型、ETA 和价格，`/api/book` 可接美团预约/下单。由于每个外部能力都被封装为独立 Tool，真实 API 上线时不改 Planning 主流程，只替换 Tool Adapter。

数据状态分为三类：一是短期会话状态，记录当前方案、已赞同节点、已拒绝节点和拒绝次数；二是用户偏好记忆，记录预算上限、通勤上限、室内优先、少排队、孩子友好等可编辑偏好；三是外部执行状态，记录详情页跳转、打车车型选择和预约结果。三类状态分离可以降低耦合，也便于评委看到后续接真实平台能力的扩展路径。

3. 异常处理机制

接口异常由 FastAPI 统一处理：`session_id` 或 `plan_id` 不存在返回 `404`，不支持的 `action` 返回 `400`。前端请求失败时保留当前方案并展示错误提示，不清空用户已有结果。

规划异常采用“校验不断流，排序来兜底”。`validate_plan` 输出预算、时长、通勤、天气、亲子适配和余位检查；有效方案优先，有问题方案扣分。如果候选被全部过滤，系统使用 `fallback_candidates`，避免无结果。连续拒绝或开放方向会触发 LLM Adapter 重排，提高召回弹性。

交互异常采用状态覆盖和防连点机制。赞同与拒绝互斥：赞同节点会移除拒绝记录，拒绝节点会移除赞同记录；整套方案赞同后仍可再次拒绝并重规划。请求进行中，前端禁用按钮和输入框，避免重复点击导致状态乱序。所有详情、打车和下单均为 Mock，不产生真实扣费或订单。

外部工具异常采用降级策略：天气失败时使用默认天气标签，路线失败时使用保守 ETA，活动检索失败时退回本地活动库，预约失败时保留方案但提示需要人工确认。LLM 接口未配置或调用失败时，系统回到规则版规划，不影响完整 Demo 演示。